

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



KỸ THUẬT DỮ LIỆU (CO5173)

Bài tập lớn

Ứng Dụng Kỹ Thuật Dữ Liệu Cho Xử Lý Dữ Liệu

GVHD: PGS.TS Võ Thị Ngọc Châu

SV thực hiện: Mai Quang Vinh - 2570375
Vương Minh Toàn - 2491057
Nguyễn Việt Hiệp - 2570192
Đỗ Hoàng Linh - 2211844
Đàm Quang Phục - 2570483

Tp. Hồ Chí Minh, tháng 1 năm 2026

Mục lục

1 DANH SÁCH THÀNH VIÊN & PHÂN CÔNG	3
2 TỔNG QUAN VỀ MICROSOFT FABRIC LAKEHOUSE	4
2.1 Giới thiệu về Microsoft Fabric Lakehouse	4
2.2 Cơ sở lý thuyết và khái niệm	6
2.2.1 Data Warehouse	6
2.2.2 Data Lake	7
2.2.3 Lakehouse và định hướng triển khai trong Microsoft Fabric	8
2.3 Kiến trúc Microsoft Fabric Lakehouse	9
2.3.1 Kiến trúc toàn hệ thống	9
2.3.2 Kiến trúc Medallion trong Microsoft Fabric Lakehouse	10
2.3.2.a Lớp Đồng (Bronze Layer)	11
2.3.2.b Lớp Bạc (Silver Layer)	11
2.3.2.c Lớp Vàng (Gold Layer)	11
2.4 So sánh các nền tảng dữ liệu hiện đại	12
2.4.1 Bảng so sánh tổng quan về kiến trúc và mục tiêu	12
2.4.2 Khả năng vận hành và yêu cầu kỹ thuật	13
2.4.3 Hệ sinh thái, AI và khả năng tích hợp	13
2.4.4 Mô hình kinh tế và chi phí	14
2.4.5 Lộ trình chiến lược và xu hướng phát triển	14
2.4.6 Kết luận và khuyến nghị	14
2.5 Thực nghiệm chức năng trên Microsoft Fabric	15
2.5.1 Tải dữ liệu mẫu và biểu diễn bằng Power BI	15
2.5.2 Kết nối tới cơ sở dữ liệu trên điện toán đám mây	19
3 QUẢN LÝ VÀ PHÂN TÍCH DỮ LIỆU TAXI NYC	24
3.1 Sơ lược về tập dữ liệu (NYC TLC Trip Record Data)	24
3.2 Vì sao chọn Microsoft Fabric	25
3.2.1 Kiến trúc dữ liệu hiện đại End-to-End	25
3.2.2 Tổng quan nền tảng Microsoft Fabric	26
3.2.3 Chi tiết kỹ thuật và biến đổi dữ liệu	26
3.2.4 Trực quan hoá và phân tích nâng cao	27



3.3	Quy trình thực hiện	28
3.3.1	Tầng Bronze	28
3.3.2	Tầng Silver	30
3.3.2.a	Biến đổi dữ liệu thời gian	30
3.3.2.b	Biến đổi dữ liệu vị trí	33
3.3.3	Tầng Gold	35
3.3.4	Mô hình Semantic và Trực quan hóa	38
3.3.5	Quản trị, bảo mật và giám sát	39
3.3.6	Tự động hoá và tối ưu	41
3.4	Kết quả phân tích & Thông tin chuyên sâu	43
3.4.1	Bảng báo cáo	43
3.4.2	Insight	44
3.4.3	Dữ liệu bất thường	45
3.4.4	Khuyến nghị vận hành & kinh doanh	46
3.4.4.a	Tái phân bổ đội xe theo vùng – giờ	46
3.4.4.b	Chiến lược giá cho khu vực sân bay	47
3.4.4.c	Khai thác cơ hội Ride-Pooling	47
3.4.4.d	Giảm chi phí vận hành và nâng cao công suất	47
4	ĐÁNH GIÁ BẢN DÙNG THỬ	48
4.1	Ưu điểm của Microsoft Fabric Trial	48
4.2	Hạn chế và thách thức	48
5	TÀI LIỆU THAM KHẢO	50



1 DANH SÁCH THÀNH VIÊN & PHÂN CÔNG

STT	Họ và Tên	MSSV	Nhiệm vụ thực hiện	Đóng góp
1	Mai Quang Vinh	2570375	Phụ trách cơ sở lý thuyết (Data Warehouse, Data Lake, Lakehouse). Tham gia xử lý dữ liệu tầng Bronze–Silver và kiểm tra chất lượng dữ liệu.	100%
2	Vương Minh Toàn	2491057	Phụ trách chính so sánh các nền tảng dữ liệu và đánh giá Microsoft Fabric Trial . Tham gia thiết kế quy trình xử lý và đề xuất khuyến nghị kỹ thuật.	100%
3	Nguyễn Việt Hiệp	2570192	–	Rút môn
4	Đỗ Hoàng Linh	2211844	Phụ trách DEMO và triển khai thực nghiệm , bao gồm ingest dữ liệu, kết nối cloud, mô hình Semantic và báo cáo Power BI. Tham gia xử lý dữ liệu Bronze–Silver.	100%
5	Đàm Quang Phục	2570483	Phụ trách kiến trúc Microsoft Fabric Lakehouse , OneLake và Medallion. Tham gia xây dựng tầng Silver–Gold , tối ưu dữ liệu và phân tích kết quả.	100%

2 TỔNG QUAN VỀ MICROSOFT FABRIC LAKEHOUSE


2.1 Giới thiệu về Microsoft Fabric Lakehouse

Trong nhiều thập kỷ qua, các doanh nghiệp đã vô tình tự giam mình trong những “ốc đảo dữ liệu” (*Data Silos*), nơi thông tin bán hàng, vận hành và quản lý nằm rời rạc, khiến bức tranh toàn cảnh về tổ chức luôn bị chia cắt và mờ nhạt. Microsoft Fabric Lakehouse ra đời không chỉ như một công cụ mới, mà là một cuộc cách mạng về tư duy nhằm chấm dứt kỷ nguyên phân mảnh này. Bằng cách thiết lập một “hệ thần kinh trung ương” duy nhất, Fabric xóa bỏ mọi rào cản giữa các phòng ban, nhường chỗ cho một dòng chảy dữ liệu thông suốt và nhất quán, giúp doanh nghiệp thoát ly khỏi việc chỉ liệt kê tính năng để thực sự bước vào một câu chuyện chuyển đổi số đầy sức nặng.




Hình 1: Mô phỏng hệ thần kinh trung ương của Fabric

Sự ra đời của Lakehouse trong Fabric là kết quả của một quá trình tiến hóa tất yếu trong kiến trúc dữ liệu. Nếu trước đây, doanh nghiệp buộc phải đánh đổi giữa sự linh hoạt, khả năng hấp thụ dữ liệu thô khổng lồ của Data Lake và hiệu suất truy vấn chặt chẽ, chính xác của Data Warehouse, thì nay ranh giới đó đã hoàn toàn bị xóa nhòa. Thực thể lai (*Hybrid*) hoàn hảo này sở hữu sức mạnh không giới hạn để tiếp nhận mọi định dạng từ con số thô đến hình ảnh, video, đồng thời vẫn duy trì tốc độ phản xạ cực nhanh cho mọi báo cáo tài chính hay phân tích thị trường, đảm bảo sự chính xác tuyệt đối đến từng con số thông qua các chuẩn mở (*Open Standards*) như Delta Lake.



Hình 2: So sánh hiệu năng và khả năng giữa Data Lake, Data Warehouse và Lakehouse

Nhịp đập thực sự của toàn bộ hệ sinh thái này chính là triết lý “OneLake – One Copy”. Có thể hình dung OneLake như một “OneDrive dành cho dữ liệu cấp tổ chức”, nơi mọi công cụ từ trí tuệ nhân tạo (AI), học máy đến Power BI đều truy cập chung vào một “nguồn sự thật duy nhất” (*Single Source of Truth*). Triết lý này không chỉ giúp doanh nghiệp tiết kiệm chi phí lưu trữ khổng lồ mà còn loại bỏ hoàn toàn rủi ro sai lệch thông tin do việc sao chép dữ liệu dư thừa gây ra.



Hình 3: OneLake như nguồn thông tin duy nhất của tổ chức

Đặc biệt, trong kỷ nguyên *AI-first*, Microsoft Fabric Lakehouse được xây dựng với tầm nhìn “Dân chủ hóa dữ liệu”, tạo ra một sân chơi chung cho mọi vai trò trong tổ chức. Đây là nơi các Kỹ sư dữ liệu (*Data Engineer*) xây dựng nền móng vững chắc, các Nhà khoa học dữ liệu (*Data Scientist*) tự do sáng tạo các mô hình dự báo, và các Chuyên viên phân tích (*Business Analyst*)

chuyển hóa những con số khô khan thành chiến lược kinh doanh sắc sảo. Hệ sinh thái này cũng là nền tảng lý tưởng để nuôi dưỡng các trợ lý ảo (*Copilot*), giúp doanh nghiệp không chỉ nhìn lại quá khứ mà còn dự đoán được tương lai trong thời gian gần như tức thì.



Hình 4: Các vai trò chính trong hệ sinh thái dữ liệu Microsoft Fabric

Tóm lại, Microsoft Fabric Lakehouse không đơn thuần là một giải pháp công nghệ, mà đóng vai trò như cột sống của doanh nghiệp số. Thông qua việc hợp nhất lưu trữ, phân tích và trí tuệ nhân tạo trong một trải nghiệm SaaS duy nhất, Fabric giúp lãnh đạo và các đội ngũ ngừng tập trung vào sự phức tạp của quản lý dữ liệu, để dành toàn bộ nguồn lực cho mục tiêu cốt lõi: tạo ra giá trị đột phá từ dữ liệu.

2.2 Cơ sở lý thuyết và khái niệm

Sự phát triển của các hệ thống dữ liệu trong doanh nghiệp gắn liền với nhu cầu ngày càng cao về lưu trữ, quản lý và phân tích thông tin phục vụ ra quyết định. Trong giai đoạn đầu, Data Warehouse đóng vai trò trung tâm trong phân tích dữ liệu có cấu trúc. Tuy nhiên, cùng với sự bùng nổ của Big Data và dữ liệu phi cấu trúc, Data Lake dần xuất hiện như một hướng tiếp cận linh hoạt hơn. Phần này trình bày cơ sở lý thuyết của hai mô hình lưu trữ dữ liệu truyền thống là Data Warehouse và Data Lake, làm nền tảng cho việc hình thành kiến trúc Lakehouse.

2.2.1 Data Warehouse

Data Warehouse (Kho dữ liệu) là mô hình lưu trữ dữ liệu truyền thống, được thiết kế chủ yếu để phục vụ phân tích nghiệp vụ và hỗ trợ ra quyết định trong doanh nghiệp. Đặc trưng cốt lõi của Data Warehouse nằm ở tính cấu trúc và chuẩn hoá dữ liệu.

Trước hết, dữ liệu trong Data Warehouse là dữ liệu có cấu trúc (structured data), được chuẩn hoá và tổ chức theo các mô hình dữ liệu xác định trước như star schema hoặc snowflake schema. Các bảng dữ liệu được thiết kế và tối ưu ngay từ đầu nhằm đáp ứng nhu cầu báo cáo, tổng hợp và phân tích.

Bên cạnh đó, Data Warehouse hỗ trợ mạnh mẽ cho OLAP (Online Analytical Processing), cho phép thực hiện các truy vấn phức tạp, tổng hợp dữ liệu theo nhiều chiều (dimension) và chỉ số (metric). Nhờ vậy, Data Warehouse đặc biệt phù hợp cho các báo cáo quản trị, dashboard điều hành và phân tích KPI trong doanh nghiệp.

Về quy trình xử lý, Data Warehouse áp dụng mô hình ETL (Extract – Transform – Load) tương đối nghiêm ngặt. Dữ liệu phải được làm sạch, biến đổi và chuẩn hoá trước khi nạp vào kho dữ liệu, qua đó đảm bảo tính nhất quán và chất lượng dữ liệu. Đồng thời, các hệ thống Data Warehouse thường hỗ trợ đầy đủ các giao dịch ACID (Atomicity, Consistency, Isolation, Durability), giúp đảm bảo tính toàn vẹn dữ liệu trong môi trường nhiều người dùng.

Nhờ các đặc điểm trên, Data Warehouse có ưu điểm nổi bật là dữ liệu chính xác, truy vấn nhanh và độ tin cậy cao cho phân tích kinh doanh. Tuy nhiên, hạn chế lớn của mô hình này là khả năng mở rộng kém khi xử lý dữ liệu quy mô rất lớn, đồng thời thiếu linh hoạt đối với dữ liệu phi cấu trúc như log hệ thống, dữ liệu cảm biến hay dữ liệu đa phương tiện.

2.2.2 Data Lake

Data Lake (Hồ dữ liệu) ra đời nhằm khắc phục những hạn chế về quy mô và tính linh hoạt của Data Warehouse, đặc biệt trong bối cảnh Big Data và AI/ML. Khác với Data Warehouse, Data Lake tập trung vào khả năng lưu trữ dữ liệu đa dạng và ở dạng thô.

Cụ thể, Data Lake cho phép lưu trữ đồng thời dữ liệu có cấu trúc, bán cấu trúc (semi-structured như JSON, XML) và phi cấu trúc (unstructured như video, audio, log). Dữ liệu thường được nạp vào hệ thống ở trạng thái nguyên bản, chưa cần chuẩn hoá ngay từ đầu.

Về mặt kiến trúc, Data Lake được thiết kế để mở rộng linh hoạt, có khả năng lưu trữ khối lượng dữ liệu rất lớn từ nhiều nguồn khác nhau với chi phí thấp. Quy trình xử lý dữ liệu thường theo hướng ELT (Load – Transform), trong đó dữ liệu được nạp trước và chỉ được biến đổi khi phát sinh nhu cầu phân tích. Cách tiếp cận này đặc biệt phù hợp cho phân tích dữ liệu lớn, khai phá dữ liệu và các bài toán Machine Learning.

Tuy nhiên, do không bắt buộc tuân thủ chặt chẽ các giao dịch ACID và không yêu cầu chuẩn hoá dữ liệu ngay từ đầu, Data Lake thường gặp thách thức về tính nhất quán và chất lượng dữ liệu. Việc quản trị, kiểm soát và đảm bảo độ tin cậy của dữ liệu trong Data Lake vì thế trở nên phức tạp hơn so với Data Warehouse.

Tóm lại, Data Lake mang lại ưu điểm vượt trội về tính linh hoạt, khả năng mở rộng và hỗ trợ đa dạng workloads, đặc biệt trong Big Data và AI/ML. Ngược lại, hạn chế của mô hình này nằm ở việc khó đảm bảo dữ liệu chính xác và nhất quán nếu thiếu cơ chế quản trị phù hợp.

Chính sự bổ sung lẫn nhau giữa Data Warehouse và Data Lake đã tạo tiền đề cho sự ra đời của kiến trúc Lakehouse, nhằm kết hợp ưu điểm của cả hai mô hình trong một nền tảng thống nhất.

2.2.3 Lakehouse và định hướng triển khai trong Microsoft Fabric

Từ những hạn chế tồn tại song song của Data Warehouse và Data Lake, kiến trúc Lakehouse được đề xuất như một hướng tiếp cận hợp nhất, nhằm kết nối khả năng phân tích chuẩn xác của kho dữ liệu truyền thống với tính linh hoạt và khả năng mở rộng của hồ dữ liệu. Về mặt khái niệm, Lakehouse là mô hình lưu trữ cho phép dữ liệu được lưu trữ trên nền tảng lưu trữ mở, đồng thời vẫn hỗ trợ các đặc tính cốt lõi vốn chỉ có ở Data Warehouse.

Một đặc điểm quan trọng của kiến trúc Lakehouse là khả năng hỗ trợ giao dịch ACID trên dữ liệu lưu trữ dạng mở. Điều này cho phép nhiều người dùng và ứng dụng có thể đồng thời đọc, ghi và cập nhật dữ liệu mà vẫn đảm bảo tính nhất quán và toàn vẹn. Bên cạnh đó, Lakehouse không ràng buộc cứng nhắc vào một mô hình dữ liệu duy nhất, mà cho phép áp dụng linh hoạt schema-on-write hoặc schema-on-read tùy theo mục tiêu phân tích, từ đó đáp ứng đa dạng nhu cầu sử dụng dữ liệu.


Trong bối cảnh Microsoft Fabric, kiến trúc Lakehouse được hiện thực hoá như một nền tảng dữ liệu hợp nhất, nơi các workload truyền thống của Data Warehouse (OLAP, báo cáo, dashboard) và các workload hiện đại (Big Data analytics, Machine Learning, AI/ML) cùng tồn tại trên một lớp dữ liệu chung. Thay vì tách biệt kho dữ liệu phục vụ BI và hồ dữ liệu phục vụ phân tích nâng cao, Microsoft Fabric Lakehouse cho phép tái sử dụng dữ liệu xuyên suốt, giảm thiểu việc sao chép và đồng bộ dữ liệu giữa các hệ thống.

Về mặt công nghệ, kiến trúc này kế thừa các chuẩn Lakehouse phổ biến như Delta Lake, Apache Iceberg hay Apache Hudi, qua đó tận dụng hệ sinh thái lưu trữ mở, đồng thời kết hợp chặt chẽ với các dịch vụ phân tích trong Microsoft Fabric. Nhờ đó, dữ liệu có thể được xử lý theo nhiều kịch bản khác nhau: từ truy vấn phân tích hiệu năng cao, xây dựng báo cáo nghiệp vụ, cho đến huấn luyện và triển khai mô hình Machine Learning trên cùng một nền tảng.

Tóm lại, trong Microsoft Fabric, Lakehouse không chỉ là sự kết hợp mang tính lý thuyết giữa Data Warehouse và Data Lake, mà còn là một kiến trúc triển khai thực tiễn. Kiến trúc này giúp tổ chức tối ưu chi phí quản lý hệ thống dữ liệu, nâng cao khả năng mở rộng và đồng thời đảm bảo tính nhất quán, tin cậy của dữ liệu, qua đó tạo nền tảng vững chắc cho các hoạt động phân tích dữ liệu và ứng dụng AI/ML ở quy mô doanh nghiệp.

2.3 Kiến trúc Microsoft Fabric Lakehouse

2.3.1 Kiến trúc toàn hệ thống



Hình 5: Kiến trúc Microsoft Fabric Lakehouse

Trong kiến trúc **Microsoft Fabric Lakehouse**, OneLake đóng vai trò là lớp lưu trữ trung tâm, được định hướng như một “OneDrive dành cho dữ liệu”, cung cấp một hồ dữ liệu logic duy nhất cho toàn bộ tổ chức. Cách tiếp cận này giúp loại bỏ tình trạng phân mảnh dữ liệu giữa các hệ thống lưu trữ rời rạc, đồng thời tạo ra một không gian dữ liệu dùng chung, nhất quán và dễ quản trị cho các workload phân tích khác nhau.

Về mặt tính mở, OneLake được xây dựng trên các chuẩn lưu trữ phổ biến trong hệ sinh thái dữ liệu hiện đại, cụ thể là Apache Parquet và Delta Lake. Việc sử dụng các định dạng mở này giúp đảm bảo khả năng tương thích với nhiều công cụ và nền tảng khác nhau, đồng thời tránh sự phụ thuộc chặt chẽ vào một nhà cung cấp duy nhất. Nhờ đó, dữ liệu trong OneLake có thể được khai thác linh hoạt cho cả các bài toán phân tích truyền thống lẫn các kịch bản Big Data và AI/ML.

Đối với nguồn dữ liệu, Microsoft Fabric hỗ trợ kết nối nhanh chóng và thuận tiện tới nhiều hệ thống khác nhau, bao gồm các dịch vụ dữ liệu trên Azure, các nền tảng dữ liệu đám mây khác cũng như các nguồn dữ liệu tại chỗ (on-premises). Khả năng kết nối đa dạng này giúp Fabric dễ dàng tích hợp vào hạ tầng dữ liệu hiện có của tổ chức mà không đòi hỏi thay đổi lớn về kiến trúc.


Trong giai đoạn thu thập dữ liệu, Fabric tích hợp sẵn hơn 200 trình kết nối dữ liệu với giao diện thân thiện, giúp đơn giản hoá quá trình xây dựng pipeline ingest dữ liệu. Đáng chú ý, tính năng *shortcuts* cho phép liên kết trực tiếp tới dữ liệu được lưu trữ ở các hệ thống bên ngoài như AWS S3 hoặc Azure Data Lake Storage Gen2 mà không cần sao chép vật lý dữ liệu. Cách tiếp cận này không chỉ giúp tiết kiệm chi phí lưu trữ mà còn giảm thiểu độ trễ và rủi ro phát sinh do trùng lặp dữ liệu.

Sau khi được thu thập, dữ liệu trong Fabric được chuyển đổi và lưu trữ theo chuẩn Delta Lake. Điều này đồng nghĩa với việc toàn bộ các công cụ trong Microsoft Fabric có thể truy cập và thao tác trên cùng một tập dữ liệu được lưu trữ trong OneLake mà không cần nhân bản dữ liệu giữa các dịch vụ. Hệ thống lưu trữ thống nhất này tạo điều kiện thuận lợi cho việc xây dựng các Lakehouse theo kiến trúc medallion (Bronze, Silver, Gold), qua đó hỗ trợ phân tầng dữ liệu theo mức độ xử lý và giá trị sử dụng.

Ở giai đoạn sử dụng dữ liệu, Microsoft Fabric cung cấp khả năng tiêu thụ dữ liệu trực tiếp từ Lakehouse cho các công cụ phân tích và báo cáo. Cụ thể, Power BI có thể khai thác dữ liệu trong Lakehouse để xây dựng báo cáo và trực quan hoá mà không cần các bước trung gian phức tạp. Bên cạnh đó, mỗi Lakehouse đều được trang bị sẵn một điểm cuối TDS (Tabular Data Stream), hay còn gọi là SQL Analytics Endpoint, cho phép các công cụ báo cáo và phân tích khác dễ dàng kết nối và truy vấn dữ liệu trong các bảng Lakehouse theo cách tương tự như làm việc với Data Warehouse truyền thống.

Tóm lại, OneLake cùng với các cơ chế thu thập, chuyển đổi và tiêu thụ dữ liệu trong Microsoft Fabric tạo nên một vòng đời dữ liệu khép kín, thống nhất và linh hoạt. Cách tiếp cận này không chỉ giúp đơn giản hoá kiến trúc hệ thống dữ liệu mà còn nâng cao hiệu quả khai thác dữ liệu cho các mục tiêu phân tích, kinh doanh và AI/ML ở quy mô doanh nghiệp.

2.3.2 Kiến trúc Medallion trong Microsoft Fabric Lakehouse



Hình 6: Kiến trúc Medallion

Kiến trúc Medallion là một mô hình thiết kế dữ liệu phổ biến trong các hệ thống Lakehouse, được sử dụng nhằm tổ chức dữ liệu theo nhiều lớp xử lý khác nhau, qua đó từng bước nâng cao chất lượng, cấu trúc và mức độ sẵn sàng cho phân tích. Cách tiếp cận đa lớp này cho phép dữ liệu được tiếp nhận ở trạng thái nguyên bản, sau đó lần lượt được làm sạch, chuẩn hoá và tinh chỉnh thông qua các giai đoạn xử lý kế tiếp. Nhờ thực hiện các phép biến đổi và kiểm soát chất lượng tại mỗi lớp, kiến trúc Medallion hướng tới việc hình thành một “nguồn thông tin duy nhất” (*single source of truth*) có độ tin cậy cao, phục vụ cho các hoạt động phân tích và ra quyết định.

2.3.2.a Lớp Đồng (Bronze Layer)

Lớp Bronze đóng vai trò là vùng tiếp nhận ban đầu cho dữ liệu thô (*raw data*) được thu thập từ nhiều nguồn khác nhau như cơ sở dữ liệu giao dịch, API, hệ thống log hoặc thiết bị IoT. Dữ liệu tại lớp này thường được lưu trữ gần như nguyên trạng, chưa qua xử lý hoặc biến đổi phức tạp. Một đặc điểm quan trọng của Bronze Layer là tính không thay đổi (*immutable*), giúp đảm bảo khả năng truy vết và kiểm toán dữ liệu (*auditability*). Nhờ đó, lớp Bronze được xem như bản ghi lịch sử đầy đủ của dữ liệu, dù khối lượng thường rất lớn và chất lượng dữ liệu chưa được đảm bảo.

2.3.2.b Lớp Bạc (Silver Layer)

Từ lớp Bronze, dữ liệu được chuyển sang lớp Silver thông qua các quy trình làm sạch và chuẩn hoá. Tại lớp này, dữ liệu được xử lý để loại bỏ hoặc sửa lỗi, xử lý các giá trị thiếu, chuẩn hoá định dạng và áp dụng các quy tắc kiểm soát chất lượng dữ liệu. Mục tiêu của Silver Layer là cung cấp một tập dữ liệu đáng tin cậy, nhất quán và có thể tái sử dụng cho nhiều mục đích phân tích khác nhau. Do đó, lớp Silver thường được xem là nền tảng trung gian, cân bằng giữa tính linh hoạt của dữ liệu thô và yêu cầu về chất lượng dữ liệu cho phân tích.

2.3.2.c Lớp Vàng (Gold Layer)

Lớp Gold là tầng dữ liệu cuối cùng trong kiến trúc Medallion, nơi dữ liệu được tinh chỉnh và tổng hợp ở mức cao, tối ưu hoá cho các nhu cầu phân tích nghiệp vụ và business intelligence. Dữ liệu tại lớp này thường được mô hình hoá theo từng trường hợp sử dụng cụ thể, chẳng hạn như báo cáo KPI, dashboard quản trị hoặc các tập dữ liệu phục vụ ra quyết định. Ngoài ra, Gold Layer cũng được tối ưu về mặt hiệu năng truy vấn, giúp các công cụ phân tích và báo cáo có thể truy cập dữ liệu nhanh chóng và hiệu quả.

Tóm lại, kiến trúc Medallion trong Microsoft Fabric Lakehouse cung cấp một cách tiếp cận có hệ thống để quản lý vòng đời dữ liệu, từ dữ liệu thô đến dữ liệu sẵn sàng cho phân tích. Việc phân tách rõ ràng các lớp Bronze, Silver và Gold không chỉ giúp nâng cao chất lượng và độ tin cậy của dữ liệu mà còn hỗ trợ mở rộng linh hoạt, tối ưu hoá hiệu năng và đơn giản hoá công tác quản trị dữ liệu trong môi trường doanh nghiệp.

2.4 So sánh các nền tảng dữ liệu hiện đại

Trong bối cảnh các doanh nghiệp ngày càng phụ thuộc vào dữ liệu để ra quyết định chiến lược, việc lựa chọn nền tảng dữ liệu phù hợp đóng vai trò then chốt đối với hiệu quả vận hành và khả năng mở rộng dài hạn. Phần này tập trung so sánh ba nền tảng dữ liệu phổ biến hiện nay gồm Microsoft Fabric, Azure Synapse Analytics và Databricks, dựa trên các khía cạnh kiến trúc, khả năng vận hành, hệ sinh thái tích hợp, mô hình chi phí và định hướng phát triển trong tương lai.

2.4.1 Bảng so sánh tổng quan về kiến trúc và mục tiêu

Tiêu chí	Microsoft Fabric	Azure Synapse Analytics	Databricks
Loại hình	SaaS (Software as a Service)	PaaS (Platform as a Service)	PaaS (Platform as a Service)
Kiến trúc	Lakehouse hợp nhất với OneLake	Kết hợp Data Warehouse và Data Lake	Open Lakehouse
Mục tiêu chính	Hợp nhất toàn bộ vòng đời dữ liệu	Tối ưu hoá OLAP và ETL truyền thống	Xử lý Big Data và AI/ML chuyên sâu
Triết lý thiết kế	“All-in-one”, đơn giản hoá vận hành	Linh hoạt theo hướng ghép nối dịch vụ	Hiệu suất cao, mã nguồn mở

Bảng 2: So sánh tổng quan kiến trúc và mục tiêu các nền tảng dữ liệu

2.4.2 Khả năng vận hành và yêu cầu kỹ thuật

Sự khác biệt cốt lõi giữa các nền tảng dữ liệu hiện đại nằm ở mức độ tự động hoá hạ tầng và yêu cầu kỹ thuật đối với đội ngũ vận hành. Microsoft Fabric được thiết kế theo hướng SaaS, trong đó hạ tầng tính toán và lưu trữ được quản lý hoàn toàn tự động. Người dùng không cần cấu hình cụm compute, giúp giảm đáng kể độ phức tạp trong triển khai và vận hành. Nhờ giao diện thân thiện và hỗ trợ low-code, Fabric phù hợp cho cả Data Analyst và Data Engineer trong các tổ chức có nguồn lực kỹ thuật hạn chế.

Ngược lại, Azure Synapse Analytics yêu cầu người dùng chủ động cấu hình và quản lý các thành phần như SQL pools, Spark pools và tài khoản lưu trữ. Điều này mang lại mức độ kiểm soát cao hơn nhưng đồng thời đòi hỏi đội ngũ có hiểu biết sâu về hệ sinh thái Azure cũng như kinh nghiệm vận hành hạ tầng dữ liệu.

Databricks là nền tảng yêu cầu trình độ kỹ thuật cao nhất trong ba giải pháp, đặc biệt là kinh nghiệm với Apache Spark. Người dùng chịu trách nhiệm quản lý cụm máy chủ, tối ưu hoá job và cấu hình chi tiết để đạt hiệu suất tối đa. Theo các thống kê triển khai thực tế, các tổ chức sử dụng Azure Synapse thường cần từ 2–3 kỹ sư vận hành, trong khi với Microsoft Fabric, con số này có thể giảm xuống còn khoảng 0.5–1 kỹ sư nhờ mức độ tự động hoá cao.

2.4.3 Hệ sinh thái, AI và khả năng tích hợp

Đặc tính	Microsoft Fabric	Azure Synapse	Databricks
Tích hợp Power BI	Rất cao (Direct Lake, tích hợp sẵn)	Trung bình (kết nối thủ công)	Tốt (Power BI, Tableau, v.v.)
Sẵn sàng cho AI	Có sẵn (Copilot, Data Science)	Hạn chế (cần Azure ML riêng)	Rất mạnh (MLflow, Agent Bricks)
Hỗ trợ đa đám mây	Thấp (chủ yếu Azure)	Thấp (chủ yếu Azure)	Rất cao (AWS, Azure, GCP)
Quản trị dữ liệu	Microsoft Purview tích hợp sẵn	Cần tích hợp Purview riêng	Unity Catalog (đa đám mây)

Bảng 3: So sánh hệ sinh thái, AI và khả năng tích hợp

2.4.4 Mô hình kinh tế và chi phí

Mô hình định giá của nền tảng dữ liệu ảnh hưởng trực tiếp đến khả năng dự báo và kiểm soát ngân sách của doanh nghiệp. Microsoft Fabric áp dụng mô hình định giá theo dung lượng (capacity-based), trong đó doanh nghiệp trả chi phí cố định hàng tháng cho các gói F-SKU. Mô hình này đã bao gồm chi phí lưu trữ, tính toán và bản quyền Power BI (từ gói F64), giúp đơn giản hoá việc quản lý chi phí. Mức giá dao động từ khoảng 156 USD/tháng (F2) đến hơn 5.000 USD/tháng (F64).

Azure Synapse Analytics sử dụng mô hình tính phí theo từng thành phần (component-based), bao gồm SQL pools, Spark pools, lưu trữ và các pipeline tích hợp. Cách tiếp cận này mang lại sự linh hoạt nhưng cũng làm tăng độ phức tạp trong dự báo và tối ưu chi phí.

Databricks áp dụng mô hình usage-based, tính phí dựa trên đơn vị DBU kết hợp với chi phí máy ảo của nhà cung cấp đám mây. Mô hình này rất linh hoạt và phù hợp với các workload biến động, tuy nhiên đòi hỏi doanh nghiệp phải giám sát chi phí chặt chẽ để tránh vượt ngân sách.

2.4.5 Lộ trình chiến lược và xu hướng phát triển

Xét về chiến lược dài hạn, Microsoft đang định vị Fabric là nền tảng dữ liệu trung tâm cho các dự án mới, trong khi Azure Synapse Analytics dần chuyển sang vai trò duy trì các hệ thống kho dữ liệu hiện hữu. Đáng chú ý, Synapse Data Explorer đã được công bố lộ trình nghỉ hưu vào tháng 10/2025, yêu cầu người dùng chuyển dịch sang Eventhouse trong Microsoft Fabric.

Trong khi đó, Databricks tiếp tục dẫn đầu về đổi mới trong lĩnh vực AI và dữ liệu lớn, với các sáng kiến như Lakebase và Agent Bricks, hướng tới các workload AI tạo sinh và xử lý dữ liệu ở quy mô rất lớn.

2.4.6 Kết luận và khuyến nghị


Từ các phân tích trên, Microsoft Fabric phù hợp với các doanh nghiệp ưu tiên sự đơn giản, đã đầu tư sâu vào hệ sinh thái Microsoft và mong muốn triển khai nhanh với đội ngũ nhân sự tinh gọn. Databricks là lựa chọn tối ưu cho các tổ chức xử lý dữ liệu quy mô lớn, yêu cầu hiệu suất cao cho AI/ML và hoạt động trên môi trường đa đám mây. Trong khi đó, Azure Synapse Analytics vẫn phù hợp cho các doanh nghiệp cần duy trì hệ thống kho dữ liệu truyền thống và yêu cầu mức độ kiểm soát tài nguyên chi tiết.

2.5 Thực nghiệm chức năng trên Microsoft Fabric

Nhằm đánh giá khả năng hỗ trợ xử lý và phân tích dữ liệu của **Microsoft Fabric Lakehouse**, nhóm tiến hành hai thực nghiệm chính: (i) tải dữ liệu mẫu và biểu diễn bằng Power BI, và (ii) kết nối tới cơ sở dữ liệu trên nền tảng điện toán đám mây. Các thực nghiệm này tập trung kiểm chứng quy trình xử lý dữ liệu từ khâu khởi tạo môi trường, lưu trữ, truy vấn cho đến trực quan hoá kết quả.


2.5.1 Tải dữ liệu mẫu và biểu diễn bằng Power BI

Trước tiên, nhóm tiến hành tạo một không gian làm việc (workspace) nhằm cô lập tài nguyên và quản lý các thành phần dữ liệu trong cùng một ngữ cảnh dự án. Workspace đóng vai trò là đơn vị quản trị cơ bản trong Microsoft Fabric, cho phép kiểm soát quyền truy cập và tổ chức các tài nguyên như Lakehouse, Notebook và báo cáo.




Hình 7: Khởi tạo workspace để quản lý tài nguyên và quyền truy cập

Sau khi tạo workspace, nhóm tiếp tục khởi tạo một Lakehouse, đây là thành phần trung tâm chịu trách nhiệm lưu trữ và quản lý dữ liệu theo kiến trúc Lakehouse. Lakehouse cho phép kết hợp lưu trữ dữ liệu dạng bảng và dữ liệu thô trên cùng một nền tảng OneLake.




Hình 8: Khởi tạo Lakehouse trong workspace

Tiếp theo, dữ liệu mẫu được tải lên Lakehouse nhằm mô phỏng quá trình ingest dữ liệu từ các nguồn bên ngoài. Bước này giúp kiểm chứng khả năng tiếp nhận dữ liệu ban đầu của hệ thống.




Hình 9: Tải dữ liệu mẫu vào Lakehouse

Từ dữ liệu đã tải lên, nhóm tiến hành tạo bảng dữ liệu nhằm chuyển đổi dữ liệu thô sang dạng có cấu trúc, sẵn sàng cho các bước truy vấn và phân tích tiếp theo.



Hình 10: Tạo bảng dữ liệu từ file dữ liệu mẫu

Để thực hiện các thao tác xử lý và truy vấn dữ liệu nâng cao, một Notebook được tạo ra. Notebook cho phép tương tác trực tiếp với dữ liệu trong Lakehouse thông qua Spark, hỗ trợ cả SQL và các ngôn ngữ lập trình dữ liệu khác.



Hình 11: Tạo Notebook để xử lý và truy vấn dữ liệu

Nhóm sử dụng Spark SQL để truy vấn dữ liệu từ các bảng trong Lakehouse. Bước này nhằm đánh giá khả năng xử lý dữ liệu phân tán và hiệu suất truy vấn của nền tảng.

```
1 select * from dimensions_customer
```

1: Truy vấn dữ liệu từ Lakehouse bằng Spark SQL

Kết quả truy vấn cho thấy dữ liệu đã được truy xuất thành công từ Lakehouse, xác nhận khả năng kết nối và xử lý dữ liệu của Spark trên nền tảng Microsoft Fabric.

The screenshot displays the Databricks workspace environment. At the top, the browser address bar shows the URL: `https://www.databricks.com/group/0360383-5580-2761-4b74-845116941054/hypranotebooks/0307776-5983-466-8128-76579594...`. The workspace navigation pane on the left includes sections for 'Home', 'Data items', 'Items', and 'Recent workspace'. The main area shows a notebook with a SQL query: `SELECT * FROM dimension_customer`. Below the query, a message states: 'Last Commit executed on this job on the MAQ Data Warehouse on 10/28/2023'. The 'Spark jobs (1 succeeded)' section shows a job named 'Resources'. The 'Table' view displays a list of 11 columns and 432 rows. The columns are: Table name, CustomerKey, WBS/CustomerKey, Customer, BBS/CustomerKey, Category, and Buysgroup. The rows list various customer keys and their corresponding categories and buy groups.


Table name	CustomerKey	WBS/CustomerKey	Customer	BBS/CustomerKey	Category	Buysgroup
1	0	0	Unknown	N/A	N/A	N/A
2	234	433	Wingate Type...	Wingate Type (Head...	Wingate Ship	Adaptive Semantics
3	235	434	Wingate Type...	Wingate Type (Head...	Wingate Ship	Says Summary
4	236	435	Wingate Type...	Wingate Type (Head...	Wingate Ship	Discontinuous Net...
5	237	436	Wingate Type...	Wingate Type (Head...	Wingate Ship	Eyes Clean
6	238	437	Wingate Type...	Wingate Type (Head...	Wingate Ship	Wingate Gray
7	239	438	Wingate Type...	Wingate Type (Head...	Wingate Ship	Diagram Nodes
8	240	439	Wingate Type...	Wingate Type (Head...	Wingate Ship	Mosa Omnidirect
9	241	440	Wingate Type...	Wingate Type (Head...	Wingate Ship	Kali Summary
10	242	441	Wingate Type...	Wingate Type (Head...	Wingate Ship	Color Advertisin...
11	243	442	Wingate Type...	Wingate Type (Head...	Wingate Ship	Rafal Ghale
12	244	443	Wingate Type...	Wingate Type (Head...	Wingate Ship	Lien-Ban
13	245	444	Wingate Type...	Wingate Type (Head...	Wingate Ship	Disruptive Challen...
14	246	445	Wingate Type...	Wingate Type (Head...	Wingate Ship	As Core Type

Hình 12: Kết quả dữ liệu truy xuất từ Spark SQL

Từ dữ liệu đã xử lý, nhóm tiếp tục tạo Semantic Model nhằm chuẩn hoá dữ liệu phục vụ cho các công cụ phân tích và trực quan hoá. Semantic Model đóng vai trò cầu nối giữa Lakehouse và Power BI.


Hình 13: Tạo Semantic Model từ dữ liệu Lakehouse

Dựa trên Semantic Model, nhóm xây dựng các biểu đồ trực quan để phân tích dữ liệu. Bước này kiểm chứng khả năng tích hợp trực tiếp giữa Lakehouse và Power BI trong Microsoft Fabric.



Hình 14: Xây dựng biểu đồ trực quan từ dữ liệu

Biểu đồ kết quả cho thấy dữ liệu được trực quan hoá thành công, chứng minh quy trình xử lý dữ liệu từ ingest đến phân tích có thể được thực hiện liền mạch trong một nền tảng duy nhất.




Hình 15: Kết quả biểu đồ trực quan hoá dữ liệu

2.5.2 Kết nối tới cơ sở dữ liệu trên điện toán đám mây


Trong thực nghiệm này, nhóm tập trung đánh giá khả năng kết nối dữ liệu thời gian gần thực (*near real-time*) giữa Microsoft Fabric và hệ thống cơ sở dữ liệu trên nền tảng điện toán đám mây. Mục tiêu của thực nghiệm là kiểm chứng khả năng truy xuất dữ liệu hiện tại, theo dõi dữ liệu lịch sử và cập nhật dữ liệu mới khi có sự kiện hoặc lệnh kích hoạt (*trigger*).

Trước tiên, nhóm khởi tạo một Dataflow Gen2 để xây dựng luồng tích hợp dữ liệu từ nguồn bên ngoài vào Microsoft Fabric. Dataflow Gen2 cho phép thiết lập pipeline ingest dữ liệu theo hướng trực quan, hỗ trợ cả chế độ làm mới định kỳ và kích hoạt theo sự kiện.




Hình 16: Khởi tạo Dataflow Gen2 để tích hợp dữ liệu từ hệ thống bên ngoài

Sau khi tạo Dataflow, nhóm lựa chọn nguồn dữ liệu cần kết nối. Microsoft Fabric hỗ trợ nhiều loại nguồn dữ liệu đám mây và cơ sở dữ liệu quan hệ, cho phép thiết lập kết nối nhanh chóng mà không yêu cầu cấu hình phức tạp.



Hình 17: Lựa chọn nguồn dữ liệu từ cơ sở dữ liệu trên cloud

Kết quả truy xuất cho thấy dữ liệu từ bảng trong cơ sở dữ liệu cloud đã được đọc thành công và hiển thị trong Dataflow. Bước này xác nhận khả năng kết nối và đồng bộ dữ liệu ban đầu giữa hệ thống bên ngoài và Microsoft Fabric.



	id	first_name	last_name	email	phone_number
1	1	John	Deere	john.deere@oracle.com	515.123.4567
2	2	Jane	Smith	jane.smith@oracle.com	515.123.4568
3	3	Robert	Johnson	robert.johnson@oracle.com	515.123.4569
4	4	Pat	King	pat.king@oracle.com	515.123.4570
5	5	Alen	Lee	alen.lee@oracle.com	515.123.4571
6	6	Wendell	Olson	wendell.olson@oracle.com	515.123.4572
7	7	Joey	Fay	joey.fay@oracle.com	515.123.4573
8	8	Pat	Haas	pat.haas@oracle.com	515.123.4574
9	9	Timothy	Chambers	timothy.chambers@oracle.com	515.123.4575
10	10	David	Green	david.green@oracle.com	515.123.4576
11	11	Pat	Haas	pat.haas@oracle.com	515.123.4577
12	12	Timothy	Chambers	timothy.chambers@oracle.com	515.123.4578
13	13	David	Green	david.green@oracle.com	515.123.4579
14	14	Pat	Haas	pat.haas@oracle.com	515.123.4580
15	15	Timothy	Chambers	timothy.chambers@oracle.com	515.123.4581
16	16	David	Green	david.green@oracle.com	515.123.4582
17	17	Pat	Haas	pat.haas@oracle.com	515.123.4583
18	18	Timothy	Chambers	timothy.chambers@oracle.com	515.123.4584
19	19	David	Green	david.green@oracle.com	515.123.4585
20	20	Pat	Haas	pat.haas@oracle.com	515.123.4586
21	21	Timothy	Chambers	timothy.chambers@oracle.com	515.123.4587
22	22	David	Green	david.green@oracle.com	515.123.4588

Hình 18: Dữ liệu được truy xuất thành công từ bảng trong cơ sở dữ liệu cloud

Song song với luồng ingest dữ liệu, nhóm triển khai một API đơn giản bằng FastAPI nhằm mô phỏng hệ thống nghiệp vụ bên ngoài có khả năng tạo và cập nhật dữ liệu. API này cho phép truy vấn danh sách bản ghi hiện có và thêm dữ liệu mới vào cơ sở dữ liệu, đóng vai trò nguồn phát sinh dữ liệu cho quá trình đồng bộ.

```


1 from typing import List, Annotated
2 from fastapi import APIRouter, Depends, status
3
4 from app.schemas.user import UserCreatedDTO, UserResponseDTO
5 from app.services.user import UserService
6 from app.core.dependencies.container import resolve_service
7
8 router = APIRouter(prefix="/users", tags=["users"])
9
10 def get_user_service() -> UserService:
11     return resolve_service(UserService)
12
13 UserServiceDep = Annotated[UserService, Depends(get_user_service)]
14
15 @router.get("/", response_model=List[UserResponseDTO])
16 async def get_all_users(user_service: UserServiceDep):
17     return user_service.get_all_users()
18
19 @router.post(

```

```
20     "/",
21     response_model=UserResponseDTO,
22     status_code=status.HTTP_201_CREATED
23 )
24 async def create_user(
25     user_data: UserCreateDTO,
26     user_service: UserServiceDep
27 ):
28     return user_service.create_user(user_data)
```


2: API FastAPI mô phỏng hệ thống tạo và cập nhật dữ liệu trên cloud

Sau khi API được kích hoạt để thêm dữ liệu mới vào cơ sở dữ liệu cloud, dữ liệu phát sinh được ghi nhận tại hệ thống nguồn. Bước này mô phỏng kịch bản dữ liệu thay đổi liên tục trong các hệ thống nghiệp vụ thực tế.



Hình 19: Thêm dữ liệu mới vào cơ sở dữ liệu thông qua API

Cuối cùng, khi Dataflow Gen2 được làm mới hoặc kích hoạt theo cấu hình, dữ liệu mới được đồng bộ và hiển thị lại trong Microsoft Fabric. Kết quả cho thấy dữ liệu đã được cập nhật thành công, chứng minh khả năng theo dõi dữ liệu lịch sử và cập nhật dữ liệu mới một cách nhất quán trong kiến trúc Fabric Lakehouse.



Hình 20: Dữ liệu được cập nhật và hiển thị lại sau khi đồng bộ

3 QUẢN LÝ VÀ PHÂN TÍCH DỮ LIỆU TAXI NYC

Phần báo cáo này trình bày một giải pháp phân tích dữ liệu toàn diện cho Ủy ban Taxi và Limousine Thành phố New York (New York City Taxi & Limousine Commission – NYC TLC) dựa trên nền tảng Microsoft Fabric. Hệ thống khai thác bộ dữ liệu hành trình công khai của NYC TLC, bao gồm dữ liệu taxi Yellow và Green, đồng thời minh họa một quy trình xử lý dữ liệu hoàn chỉnh từ khâu thu thập dữ liệu quy mô lớn đến phân tích nâng cao và trực quan hóa.

3.1 Sơ lược về tập dữ liệu (NYC TLC Trip Record Data)

Bộ dữ liệu NYC TLC Trip Record là một bộ dữ liệu mở có quy mô rất lớn, ghi nhận thông tin chi tiết về các chuyến đi taxi tại Thành phố New York từ năm 2009 đến nay. Bộ dữ liệu bao phủ chủ yếu hai nhóm dịch vụ taxi là *Yellow* và *Green*, qua đó phản ánh đặc trưng di chuyển đô thị theo thời gian và theo khu vực.

Về nguồn dữ liệu, thông tin chuyến đi được thu thập bởi các nhà cung cấp công nghệ theo các chương trình TPEP/LPEP và được NYC TLC công bố dưới dạng dữ liệu mở. Cần lưu ý rằng NYC TLC không trực tiếp tạo ra dữ liệu, mà đóng vai trò tổng hợp và cung cấp dữ liệu cho cộng đồng nhằm phục vụ mục đích nghiên cứu và khai thác công khai.

Về quy mô, bộ dữ liệu chứa hàng tỷ bản ghi, với hàng trăm triệu chuyến đi mỗi năm. Dữ liệu thường được phát hành theo tháng và được lưu trữ dưới các định dạng dạng cột (columnar) như Parquet nhằm tối ưu hiệu năng truy vấn và xử lý dữ liệu quy mô lớn. Nhờ tính sẵn có công khai và định dạng chuẩn hoá, bộ dữ liệu có thể được truy cập thuận tiện thông qua các điểm truy cập công cộng hoặc các dịch vụ lưu trữ đám mây như Azure Blob Storage.

Các thuộc tính cốt lõi của dữ liệu bao gồm: thời điểm đón/trả khách, thông tin khu vực taxi, quãng đường di chuyển, cấu phần cước phí, phương thức thanh toán, mã nhà cung cấp (vendor) và số lượng hành khách. Tuy nhiên, do đặc thù dữ liệu mở với quy mô lớn, dữ liệu vẫn cần được kiểm định và làm sạch nhằm xử lý các vấn đề thường gặp như giá trị thiếu, ngoại lệ (outliers) và các bản ghi không nhất quán trước khi đưa vào phân tích.

Các trường dữ liệu sử dụng trong bài toán:

Nguồn chính của báo cáo là hồ sơ chuyến đi của taxi Vàng (Yellow) và Xanh lá (Green) thuộc bộ dữ liệu NYC TLC. Các trường cốt lõi được sử dụng bao gồm:

- **pickup_datetime, dropoff_datetime:** Thời gian đón và trả khách.
- **pickup_location_id, dropoff_location_id:** Mã khu vực taxi tại điểm đón và điểm

trả.

- **trip_distance**: Quãng đường di chuyển (dặm).
- **fare_amount, tip_amount, tolls_amount, total_amount**: Các cấu phần chi phí và tổng tiền.
- **payment_type, vendor_id, passenger_count**: Hình thức thanh toán, mã nhà cung cấp và số lượng hành khách.

Ngoài các trường gốc, báo cáo xây dựng thêm các trường phát sinh (*derived fields*) phục vụ lớp Gold nhằm tối ưu cho phân tích nghiệp vụ và trực quan hoá:

- **trip_duration_minutes**: Thời gian di chuyển (phút).
- **trip_speed_mph**: Tốc độ trung bình (dặm/giờ).
- **is_rush_hour**: Cờ đánh dấu chuyến đi trong giờ cao điểm.
- **day_of_week, hour_of_day, is_holiday**: Các thuộc tính thời gian phục vụ phân tích theo ngày/giờ và ngày lễ.
- **origin_zone_name, destination_zone_name**: Tên khu vực tại điểm đi và điểm đến.

3.2 Vì sao chọn Microsoft Fabric

3.2.1 Kiến trúc dữ liệu hiện đại End-to-End

Giải pháp được xây dựng theo một kiến trúc phân tích dữ liệu *end-to-end* gồm bốn giai đoạn, nhằm đảm bảo luồng dữ liệu xuyên suốt từ dữ liệu thô đến các insight phục vụ kinh doanh. Toàn bộ chu trình này được triển khai trọn vẹn trong Microsoft Fabric, nhờ tính hợp nhất về lưu trữ, xử lý và tiêu thụ dữ liệu trên cùng một nền tảng.

(1) Thu thập dữ liệu (Data Ingestion). Các tệp dữ liệu thô ở định dạng Parquet/CSV được thu thập thông qua Data Pipelines – công cụ tích hợp dữ liệu theo hướng low-code của Fabric. Dữ liệu có thể được lấy từ các HTTP endpoints công khai hoặc từ Azure Blob Storage, sau đó được đưa vào khu vực staging trong OneLake để chuẩn bị cho các bước xử lý tiếp theo.

(2) Lưu trữ dữ liệu (Data Storage). Sau khi thu thập, dữ liệu được lưu trữ trong Lakehouse trên OneLake dưới định dạng Delta Lake. Cách tiếp cận này vừa đảm bảo tính nhất quán và khả năng quản lý phiên bản dữ liệu, vừa cung cấp nền tảng lưu trữ có khả năng mở rộng, phù hợp cho xử lý dữ liệu quy mô lớn.

(3) **Xử lý dữ liệu (Data Processing).** Quá trình biến đổi và làm giàu dữ liệu được triển khai bằng Spark Notebooks. Tại giai đoạn này, hệ thống thực hiện làm sạch dữ liệu, chuẩn hoá các trường thông tin và xây dựng đặc trưng (*feature engineering*) trên nền tảng xử lý phân tán của Spark, qua đó nâng cao mức độ sẵn sàng của dữ liệu cho phân tích nâng cao và mô hình hoá.

(4) **Cung cấp dữ liệu (Data Serving).** Dữ liệu sau xử lý được phục vụ cho người dùng cuối thông qua Power BI Direct Lake và SQL Analytics Endpoints. Cơ chế này hỗ trợ phân tích gần thời gian thực (*near real-time*) và hạn chế sao chép dữ liệu không cần thiết, giúp đảm bảo tính nhất quán giữa tầng dữ liệu và tầng báo cáo.

Nhìn chung, kiến trúc trên đảm bảo một pipeline dữ liệu liền mạch từ ingest đến phân tích và trực quan hoá, đồng thời tận dụng lợi thế hợp nhất của Microsoft Fabric để đơn giản hoá triển khai và vận hành.

3.2.2 Tổng quan nền tảng Microsoft Fabric

Microsoft Fabric được lựa chọn làm nền tảng phân tích trung tâm nhờ kiến trúc SaaS hợp nhất và khả năng tích hợp chặt chẽ giữa các dịch vụ dữ liệu trong cùng một workspace. Trước hết, Fabric cung cấp *unified tooling* khi tích hợp Data Factory, Data Engineering (Spark), SQL Analytics (Synapse), Data Warehouse và Power BI trong một môi trường thống nhất, qua đó giảm đáng kể độ phức tạp khi triển khai và quản trị nhiều dịch vụ rời rạc.

Bên cạnh đó, OneLake được định vị như “OneDrive cho dữ liệu”, đóng vai trò hồ dữ liệu tập trung cho toàn tổ chức. Nhờ việc tất cả các workload (pipelines, Spark, SQL và Power BI) cùng truy cập một nguồn dữ liệu duy nhất, Fabric giúp hạn chế tình trạng phân mảnh dữ liệu (*data silos*) và giảm thiểu nhu cầu đồng bộ/nhân bản dữ liệu giữa các hệ thống.

Ngoài các năng lực xử lý dữ liệu, Fabric còn tích hợp AI thông qua Copilot, hỗ trợ tăng tốc phát triển bằng cách sinh câu lệnh SQL, mã Spark và tóm tắt phân tích từ ngôn ngữ tự nhiên. Trên phương diện vận hành, với đặc trưng là nền tảng SaaS được quản lý, Fabric cung cấp sẵn cơ chế quản trị, phân quyền truy cập và cập nhật tự động, qua đó giúp giảm đáng kể chi phí vận hành hệ thống trong bối cảnh triển khai dữ liệu quy mô doanh nghiệp.

3.2.3 Chi tiết kỹ thuật và biến đổi dữ liệu

Lưu trữ tối ưu với Delta Lake. Dữ liệu trong Lakehouse được lưu trữ dưới định dạng Delta Lake (Delta Parquet), mang lại nhiều lợi ích quan trọng. Trước hết, Delta Lake hỗ trợ giao dịch ACID, đảm bảo các thao tác cập nhật dữ liệu diễn ra nhất quán ngay cả khi có nhiều

tiến trình đọc/ghi đồng thời. Bên cạnh đó, cơ chế *time travel* cho phép truy vấn và khôi phục các phiên bản dữ liệu trước đó, hỗ trợ kiểm toán, truy vết và phân tích lịch sử. Về hiệu năng và chi phí, lưu trữ dạng cột giúp tối ưu dung lượng thông qua nén dữ liệu và cải thiện tốc độ truy vấn. Đồng thời, bảng Delta có thể được truy cập trực tiếp bởi Spark, SQL Analytics Endpoints và Power BI Direct Lake, tạo điều kiện cho *zero-copy analytics* trên cùng một lớp dữ liệu.

Kỹ thuật dữ liệu với Spark. Spark Notebooks được sử dụng để triển khai các tác vụ kỹ thuật dữ liệu cốt lõi. Quá trình làm sạch tập trung loại bỏ các bản ghi không hợp lệ như chuyến đi có quãng đường bằng 0 hoặc chi phí âm; đồng thời chuẩn hoá định dạng thời gian, mã nhà cung cấp và các trường phân loại để đảm bảo tính nhất quán. Tiếp theo, hệ thống thực hiện xây dựng đặc trưng (*feature engineering*) nhằm phục vụ phân tích, bao gồm: *trip_duration_minutes* (thời lượng chuyến đi), *distance_miles* (khoảng cách đã chuẩn hoá), và cờ giờ cao điểm (*rush hour flag*) để xác định các chuyến đi trong các khung giờ 07:00–09:00 và 17:00–19:00. Ngoài ra, các đặc trưng thời gian bổ sung như thứ trong tuần, ngày lễ và nhóm thời gian trong ngày được khai thác để hỗ trợ phân tích hành vi di chuyển. Để tối ưu hiệu năng trên tập dữ liệu lớn, dữ liệu được phân vùng theo thời gian hoặc khu vực, đồng thời áp dụng cache cho các kết quả trung gian khi cần thiết.

Những bước biến đổi này đảm bảo dữ liệu đầu ra sạch, giàu thông tin và sẵn sàng cho các bài toán phân tích nâng cao.

3.2.4 Trực quan hoá và phân tích nâng cao

Microsoft Fabric hỗ trợ kết hợp chặt chẽ giữa truy vấn dữ liệu và trực quan hoá thông qua SQL Analytics Endpoints và Power BI Direct Lake.

SQL Analytics Endpoints. Fabric tự động cung cấp SQL Analytics Endpoints cho các bảng Delta, cho phép truy vấn dữ liệu Lakehouse bằng T-SQL tiêu chuẩn. Cơ chế này hỗ trợ *zero-copy analytics*, trong đó truy vấn SQL quy mô lớn được thực thi trực tiếp trên OneLake mà không cần di chuyển dữ liệu sang một kho dữ liệu độc lập.

Power BI Direct Lake Mode. Direct Lake cho phép Power BI đọc trực tiếp các tệp Delta Parquet trên OneLake, mang lại hiệu năng gần tương đương chế độ Import trong khi vẫn duy trì khả năng mở rộng đến hàng tỷ bản ghi. Nhờ cơ chế đọc trực tiếp dữ liệu, báo cáo có thể phản ánh dữ liệu gần thời gian thực mà không cần refresh dataset theo cách truyền thống, đồng thời giảm trùng lặp dữ liệu và đảm bảo tính nhất quán giữa tầng SQL và tầng BI.

Tóm lại, sự kết hợp giữa SQL Analytics Endpoints và Power BI Direct Lake tạo ra một chuỗi khai thác dữ liệu hiệu quả cho bài toán taxi NYC, cho phép phân tích từ các chỉ số vận hành


chi tiết đến các insight chiến lược ở cấp độ quản trị.

3.3 Quy trình thực hiện

3.3.1 Tầng Bronze


Tầng Bronze đóng vai trò là lớp tiếp nhận dữ liệu ban đầu trong kiến trúc Medallion, nơi dữ liệu được thu thập và lưu trữ ở trạng thái gần với dữ liệu gốc nhất. Mục tiêu của tầng này là đảm bảo khả năng truy vết và kiểm toán dữ liệu, đồng thời thực hiện các bước tiền xử lý tối thiểu nhằm loại bỏ các bản ghi không hợp lệ trước khi chuyển sang các tầng xử lý tiếp theo.

Trước tiên, nhóm tiến hành tạo một workspace để quản lý các tài nguyên liên quan đến quy trình xử lý dữ liệu. Sau đó, các tệp dữ liệu mẫu được tải lên nhằm mô phỏng quá trình ingest dữ liệu từ các nguồn bên ngoài vào Microsoft Fabric.




Hình 21: Tải dữ liệu mẫu vào workspace tại tầng Bronze

Sau khi dữ liệu được tải lên, hệ thống yêu cầu xác định đích đến của dữ liệu sau khi xử lý. Trong kiến trúc này, dữ liệu được đưa vào Lakehouse thuộc OneLake để đảm bảo tính nhất quán và khả năng tái sử dụng cho các tầng Silver và Gold.



Hình 22: Xác định Lakehouse làm điểm lưu trữ dữ liệu tầng Bronze

Tại tầng Bronze, nhóm thực hiện bước tiền xử lý cơ bản nhằm loại bỏ các bản ghi không hợp lệ. Cụ thể, các bản ghi có giá trị *null* tại một trong hai trường thời gian đón hoặc trả khách (*pickup_datetime* và *dropoff_datetime*) được loại bỏ. Việc làm sạch ở mức tối thiểu này giúp đảm bảo dữ liệu đầu vào có chất lượng cơ bản, đồng thời vẫn giữ được đặc trưng “raw data” của tầng Bronze.



Hình 23: Loại bỏ các bản ghi không hợp lệ tại tầng Bronze

Nhìn chung, tầng Bronze trong quy trình thực hiện đảm bảo dữ liệu được thu thập đầy đủ, có khả năng truy vết và đạt mức chất lượng tối thiểu, tạo nền tảng cho các bước làm sạch, chuẩn hoá và làm giàu dữ liệu ở tầng Silver.

3.3.2 Tầng Silver

Tầng Silver đóng vai trò trung gian quan trọng trong kiến trúc Lakehouse, nơi dữ liệu thô từ tầng Bronze được làm sạch, chuẩn hóa và biến đổi thành dữ liệu có cấu trúc, sẵn sàng cho các bước phân tích chuyên sâu ở tầng Gold. Tại giai đoạn này, các phép biến đổi tập trung vào hai nhóm chính: dữ liệu thời gian và dữ liệu vị trí, nhằm bổ sung ngữ nghĩa và giá trị phân tích cho bộ dữ liệu chuyển taxi.

3.3.2.a Biến đổi dữ liệu thời gian


Mục tiêu và lưu trữ. Dữ liệu sau biến đổi được lưu trữ tại Silver Layer trong Lakehouse nhằm đảm bảo tính chuẩn hóa và khả năng tái sử dụng. Đầu vào tập trung vào hai trường thời gian chính là *tpep_pickup_datetime* và *tpep_dropoff_datetime*.

Quy trình mapping và làm sạch (Dataflow Gen2). Quá trình biến đổi được thực hiện thông qua Power Query trong Dataflow Gen2 với các bước chính sau:

- **Tạo cột Duration:** Thời lượng chuyến đi được tính bằng hiệu giữa thời điểm trả khách và đón khách, sau đó quy đổi sang đơn vị phút (*Total minutes*). Trường này phục vụ cho việc phân tích chuyến đi ngắn, dài và đánh giá hiệu quả vận hành.




- **Tạo cột Hour:** Trích xuất giờ trong ngày từ thời điểm đón khách để phục vụ phân tích khung giờ cao điểm.



Hình 25: Tạo cột Hour

- **Tạo cột WeekDay:** Trích xuất ngày trong tuần từ thời điểm đón khách nhằm phân tích các ngày có lưu lượng cao.



Hình 26: Tạo cột WeekDay


Sau khi hoàn tất các phép biến đổi, các cột không cần thiết được loại bỏ nhằm tối ưu dung lượng lưu trữ và hiệu năng truy vấn tại tầng Silver.

3.3.2.b Biến đổi dữ liệu vị trí

Mục tiêu và lưu trữ. Dữ liệu vị trí sau xử lý được lưu trữ tại Silver Layer, tập trung vào hai trường chính là *pickup_location_id* và *dropoff_location_id*, nhằm bổ sung thông tin địa lý có ý nghĩa nghiệp vụ.


Quy trình mapping và làm sạch (Dataflow Gen2). Quá trình xử lý được thực hiện thông qua Power Query với các bước chính:

- **Kết nối dữ liệu bổ trợ:** Sử dụng bảng tra cứu *taxi_zone_lookup.csv* để ánh xạ mã vị trí sang thông tin khu vực chi tiết.




Hình 27: Kết nối dữ liệu bổ trợ

- **Merged Queries:** Thực hiện hai phép nối (Join) lần lượt cho điểm đón và điểm trả để bổ sung thông tin Quận (Borough) và Khu vực (Zone).



Hình 28: Thực hiện join dữ liệu vị trí đón và trả

- **Chuẩn hóa cấu trúc:** Loại bỏ các cột không cần thiết, mở rộng bảng tra cứu và đổi tên cột theo chuẩn nghiệp vụ (ví dụ: *Pickup_Borough*, *DropOff_Zone*).




Hình 29: Dữ liệu vị trí sau khi làm sạch và chuẩn hóa

Tổng kết lại, tầng Silver đã hoàn thiện việc chuẩn hóa dữ liệu thời gian và vị trí, tạo ra bộ dữ liệu có cấu trúc rõ ràng, giàu ngữ nghĩa và sẵn sàng cho các bước tích hợp, tổng hợp và tối ưu hóa tại tầng Gold.

3.3.3 Tầng Gold

Tại tầng Gold, dữ liệu được hoàn thiện và tối ưu hoá nhằm phục vụ trực tiếp cho các nhu cầu phân tích và trực quan hoá trong môi trường BI. Trên cơ sở dữ liệu đã được chuẩn hoá ở các tầng trước, nhóm xây dựng bảng **silver_yellow_trip_bi_ready** làm nền tảng trung gian cho quá trình tổng hợp và tối ưu dữ liệu phân tích.

Quá trình xử lý tại tầng này bao gồm ba nhóm tác vụ chính. Thứ nhất, **tích hợp dữ liệu (Integration)** được thực hiện bằng cách kết hợp bảng lõi **yellow_trip** với các bảng chiều (*dimension tables*), giúp dữ liệu được tổ chức theo cấu trúc phù hợp cho truy vấn phân tích. Thứ hai, **làm giàu dữ liệu (Enrichment)** thông qua việc hợp nhất các đặc tính phương tiện từ bảng **yellow_trip_taxi_features**, qua đó bổ sung thêm thông tin phục vụ phân tích đội xe. Cuối cùng, **định vị dữ liệu (Localization)** được triển khai bằng cách ánh xạ bảng **yellow_trip_PU_DO_location** nhằm xác định chính xác khu vực đón và trả khách.



Hình 30: Quá trình biến đổi và làm giàu dữ liệu tại tầng Gold

Để đảm bảo hiệu suất truy vấn trong môi trường business intelligence, quy trình xử lý tiếp tục được tinh chỉnh thông qua các bước lọc dữ liệu. Cụ thể, tập dữ liệu được giới hạn trong phạm vi năm 2025, đồng thời loại bỏ các bản ghi có giá trị trống (*null*) hoặc không hợp lệ, nhằm giảm khối lượng dữ liệu cần xử lý và nâng cao độ tin cậy của kết quả phân tích.



Hình 31: Lọc dữ liệu theo phạm vi thời gian và điều kiện hợp lệ

```
# 4. TÍNH TOÁN CÁC CỘT MỚI
df_with_derived = df_distinct.withColumn(
    "duration",
    (F.col("tpep_dropoff_datetime").cast('long') - F.col("tpep_pickup_datetime").cast('long')) / 60
).withColumn(
    "hour",
    F.hour(F.col("tpep_pickup_datetime"))
).withColumn(
    "weekday_num",
    dayofweek(F.col("tpep_pickup_datetime"))
).withColumn(
    "weekday",
    when(col("weekday_num") == 1, "Sunday")
    .when(col("weekday_num") == 2, "Monday")
    .when(col("weekday_num") == 3, "Tuesday")
    .when(col("weekday_num") == 4, "Wednesday")
    .when(col("weekday_num") == 5, "Thursday")
    .when(col("weekday_num") == 6, "Friday")
    .otherwise("Saturday")
).drop("weekday_num")

# 5. CHỌN CÁC CỘT CUỐI CÙNG
df_final = df_with_derived.select(
    "VendorID",
    "tpep_pickup_datetime",
    "tpep_dropoff_datetime",
    "passenger_count",
    "trip_distance",
    "total_amount",
    "duration",
    "hour",
    "weekday",
    "Pickup_Borough",
    "Pickup_Zone",
    "Dropoff_Borough",
    "Dropoff_Zone"
)
```

Hình 32: Loại bỏ các bản ghi không hợp lệ trong quá trình tối ưu


Sau các bước làm sạch và tinh chỉnh, tầng Gold được hoàn thiện thông qua việc xây dựng bảng **gold_taxi_trips_optimized_fast**. Bảng này được thiết kế nhằm tối ưu hiệu năng truy vấn, cho phép các báo cáo và dashboard phản hồi trong thời gian dưới một giây, đáp ứng yêu cầu khai thác dữ liệu tương tác trong Power BI.

```
1 from pyspark.sql import functions as F
2 from pyspark.sql.functions import year, month, dayofmonth, col
3
4 # 1. TẠO CÁC CỘT PHÂN VÙNG MỚI (Pickup Year, Month, Day)
5 # Các cột này để phân vùng
6 df_partitioned = df_final.withColumn(
7     "pickup_year", year(col("tpep_pickup_datetime"))
8 ).withColumn(
9     "pickup_month", month(col("tpep_pickup_datetime"))
10 ).withColumn(
11     "pickup_day", dayofmonth(col("tpep_pickup_datetime"))
12 )
13
14 # --- PHÂN TỐI ƯU TỐC ĐỘ GHI ---
15 # SỐ PARTITION MỤC TIÊU: Chọn một số lượng lớn hơn mặc định của Spark.
16 # Ví dụ: 512 hoặc 1024, tùy vào công suất Fabric của bạn.
17 # Nếu bạn không rõ, 512 là một con số an toàn để bắt đầu.
18 TARGET_PARTITIONS = 512
19
20 # 2. PHÂN BỐ LẠI DỮ LIỆU (REPARTITION)
21 # Đây là một thao tác Shuffle khác, nhưng nó chuẩn bị dữ liệu cho việc ghi song song hiệu quả hơn
22 # sau khi thao tác DISTINCT nặng nề đã hoàn thành.
23 df_repartitioned = df_partitioned.repartition(TARGET_PARTITIONS)
24
25 # 3. TẠO TÊN BẢNG MỚI
26 GOLD_TABLE_NAME_PARTITIONED = "gold_taxi_trips_optimized_fast"
27
28 # 4. GHI DỮ LIỆU VÀO LAKEHOUSE
29 print("Bắt đầu thực thi và ghi dữ liệu song song vào bảng '{GOLD_TABLE_NAME_PARTITIONED}'.")
30
31 df_repartitioned.write.format("delta") \
32     .mode("overwrite") \
33     .partitionBy("pickup_year", "weekday") \
34     .saveAsTable(GOLD_TABLE_NAME_PARTITIONED)
```

Hình 33: Tạo bảng *gold_taxi_trips_optimized_fast*

Bảng **gold_taxi_trips_optimized_fast** sau khi được tạo đã trải qua đầy đủ các bước

xử lý, làm sạch và tối ưu hoá. Bộ dữ liệu ở tầng Gold này đóng vai trò như một “nguồn dữ liệu tiêu chuẩn”, sẵn sàng để đưa lên lớp ngữ nghĩa (*semantic layer*), đảm bảo rằng các báo cáo và phân tích tiếp theo đều dựa trên dữ liệu đã được kiểm soát chất lượng và nhất quán.




taxi_id	passenger_id	trip_distance	trip_duration	trip_start_time	trip_end_time	trip_status	trip_type	trip_subtype	trip_category
1	2	2025-08-08T15:...	2025-08-08T15:...	1	1.36	20.25	17.45	12	Passenger
2	2	2025-08-07T15:...	2025-08-07T15:...	1	17.82	86.44	68.93333333333333	17	Passenger
3	2	2025-08-07T14:...	2025-08-07T14:...	3	1.3	14.75	9.716666666666667	14	Passenger
4	2	2025-07-18T09:...	2025-07-18T09:...	2	2.33	28.62	20.5	9	Passenger
5	2	2025-08-10T18:...	2025-08-10T18:...	1	5.55	33.23	25.7	18	Passenger
6	1	2025-07-18T05:...	2025-07-18T05:...	1	1.8	20.75	13.116666666666667	20	Passenger
7	2	2025-08-07T18:...	2025-08-07T18:...	1	7.1	47.85	28.9	18	Passenger
8	2	2025-07-18T05:...	2025-07-18T05:...	2	4.28	27.85	20.916666666666667	20	Passenger
9	1	2025-08-08T15:...	2025-08-08T15:...	3	1.8	21.9	14.533333333333333	15	Passenger
10	1	2025-08-22T06:...	2025-08-22T07:...	1	1.5	14.25	9.833333333333333	9	Passenger

Hình 34: Hoàn tất tầng Gold và sẵn sàng cho phân tích

3.3.4 Mô hình Semantic và Trực quan hóa

Sau khi hoàn tất tầng Gold, dữ liệu được đưa vào lớp ngữ nghĩa (Semantic Layer) nhằm phục vụ trực tiếp cho các hoạt động phân tích và trực quan hoá. Microsoft Fabric tận dụng hệ sinh thái OneLake để hợp nhất dữ liệu từ Lakehouse mà không cần sao chép nhiều lần, qua đó đảm bảo tính nhất quán và giảm thiểu chi phí lưu trữ.


Quy trình xây dựng mô hình Semantic được thực hiện trực tiếp trên nền tảng Fabric. Cụ thể, người dùng truy cập Danh mục OneLake, điều hướng đến Yellow Trip Lakehouse và lựa chọn các bảng dữ liệu đã được chuẩn bị ở tầng Gold. Tại đây, chức năng “Mô hình ngữ nghĩa mới” được sử dụng để xác định các mối quan hệ giữa bảng dữ liệu cũng như các phép đo (measures) phục vụ phân tích. Trong thực nghiệm này, bảng *gold_taxi_trips_optimized_fast* được lựa chọn làm bảng trung tâm của mô hình.



Hình 35: Xây dựng mô hình Semantic từ dữ liệu tầng Gold


Sau khi mô hình Semantic được tạo, Fabric cho phép xây dựng báo cáo Power BI trực tiếp thông qua quy trình làm việc liền mạch (*seamless workflow*). Người dùng chỉ cần nhấp chuột phải vào mô hình ngữ nghĩa vừa tạo và chọn chức năng “Tạo báo cáo”, hệ thống sẽ tự động mở

giao diện soạn thảo Power BI với dữ liệu đã được liên kết sẵn.



Hình 36: Khởi tạo báo cáo Power BI từ mô hình Semantic

Giao diện Power BI cho phép xây dựng các biểu đồ và dashboard dựa trên mô hình Semantic mà không cần thêm các bước cấu hình trung gian. Cách tiếp cận này giúp rút ngắn thời gian từ dữ liệu đến báo cáo, đồng thời đảm bảo rằng toàn bộ quá trình phân tích và trực quan hoá đều dựa trên cùng một nguồn dữ liệu đã được kiểm soát chất lượng ở tầng Gold.




Hình 37: Giao diện xây dựng báo cáo Power BI

3.3.5 Quản trị, bảo mật và giám sát

Microsoft Fabric Lakehouse cung cấp các cơ chế quản trị và bảo mật nhằm kiểm soát quyền truy cập dữ liệu, bảo vệ dữ liệu nhạy cảm, đảm bảo tuân thủ các quy định và hỗ trợ truy vết toàn bộ vòng đời dữ liệu trong hệ thống. Các chức năng này đặc biệt quan trọng khi triển khai nền tảng phân tích dữ liệu trong môi trường nhiều người dùng và nhiều vai trò khác nhau.


3.3.5.1 Quản trị workspace và phân quyền người dùng Quản trị được thực hiện ở cấp độ workspace, nơi người quản trị có thể gán các vai trò như *Admin*, *Member* và *Viewer* cho từng

người dùng. Cách phân quyền này giúp kiểm soát phạm vi thao tác, từ quản lý tài nguyên, chỉnh sửa dữ liệu đến chỉ xem báo cáo.




Hình 38: Quản trị người dùng và phân quyền trong workspace

3.3.5.2 Thiết lập quyền truy cập dữ liệu Ở cấp độ dữ liệu, Microsoft Fabric cho phép phân quyền chi tiết thông qua SQL Analytics Endpoint. Người quản trị có thể sử dụng các câu lệnh SQL để cấp hoặc thu hồi quyền truy cập đối với bảng và view, qua đó đảm bảo người dùng chỉ có thể truy cập các dữ liệu phù hợp với vai trò của mình. Trong trường hợp cần thiết, các cơ chế bảo mật nâng cao như Row-Level Security (RLS) hoặc Column-Level Security (CLS) cũng có thể được cấu hình.




Hình 39: Phân quyền truy cập dữ liệu bằng câu lệnh SQL

3.3.5.3 Kiểm soát truy cập thông qua view Để đơn giản hoá việc chia sẻ dữ liệu và tăng cường bảo mật, hệ thống cho phép tạo các view trung gian cho người dùng cuối. Các view này chỉ phơi bày những trường thông tin cần thiết, đồng thời ẩn các dữ liệu nhạy cảm hoặc không liên quan đến mục đích phân tích.



Hình 40: Tạo view dữ liệu phục vụ phân quyền người dùng

3.3.5.4 Gán nhãn dữ liệu, lineage và giám sát Microsoft Fabric hỗ trợ gán nhãn độ nhạy dữ liệu (*sensitivity labels*) như Public hoặc Confidential nhằm hỗ trợ quản trị rủi ro và tuân thủ. Bên cạnh đó, hệ thống cho phép theo dõi lineage dữ liệu, giúp xác định rõ luồng dữ liệu từ nguồn, qua các bước xử lý cho đến báo cáo cuối cùng. Các hoạt động truy cập và thay đổi dữ liệu cũng được ghi nhận thông qua cơ chế giám sát và audit, hỗ trợ kiểm tra và phân tích sự cố khi cần thiết.



Hình 41: Giám sát hệ thống và truy vết lineage dữ liệu

3.3.6 Tự động hoá và tối ưu

Nhằm nâng cao hiệu quả vận hành và giảm thiểu sự can thiệp thủ công, Microsoft Fabric Lakehouse cung cấp các cơ chế tự động hoá giúp người quản trị và đội ngũ phát triển xây dựng quy trình xử lý dữ liệu nhất quán, có khả năng mở rộng và tối ưu chi phí.

3.3.6.1 Xây dựng pipeline tự động Bước đầu tiên trong quá trình tự động hoá là xây dựng các pipeline xử lý dữ liệu theo mô hình ingest-transform-load. Các pipeline này có thể kết nối linh hoạt tới nhiều thành phần khác nhau trong Fabric như Dataflow Gen2, Spark Notebook

hoặc các tập lệnh SQL, cho phép triển khai toàn bộ quy trình xử lý dữ liệu trong một luồng thống nhất.


3.3.6.2 Thiết lập trigger và lịch chạy Sau khi pipeline được xây dựng, hệ thống cho phép cấu hình các trigger tự động nhằm kiểm soát thời điểm thực thi. Pipeline có thể được thiết lập chạy theo lịch định kỳ (theo giờ hoặc theo ngày) hoặc kích hoạt khi có dữ liệu mới phát sinh, qua đó đảm bảo dữ liệu luôn được cập nhật kịp thời mà không cần thao tác thủ công.

3.3.6.3 Xử lý dữ liệu theo hướng incremental Để tối ưu hiệu năng và chi phí, quy trình xử lý được thiết kế theo hướng incremental, chỉ xử lý các bản ghi mới hoặc đã thay đổi thay vì thực hiện full load toàn bộ dữ liệu. Cách tiếp cận này đặc biệt hiệu quả đối với các tập dữ liệu lớn, giúp giảm đáng kể thời gian xử lý và tài nguyên tiêu thụ.

3.3.6.4 Tối ưu lưu trữ và truy vấn Ở giai đoạn lưu trữ, dữ liệu được tối ưu thông qua các kỹ thuật như gộp các tệp nhỏ (*OPTIMIZE*), sắp xếp dữ liệu theo Z-Order và phân vùng dữ liệu hợp lý. Các biện pháp này giúp cải thiện hiệu năng truy vấn, đặc biệt đối với các truy vấn phân tích trên tập dữ liệu quy mô lớn.

3.3.6.5 Giám sát và phát hiện lỗi Microsoft Fabric cung cấp công cụ giám sát cho phép theo dõi chi tiết trạng thái thực thi của pipeline, bao gồm số lần chạy, thời gian xử lý và các lỗi phát sinh. Thông tin giám sát này hỗ trợ người quản trị nhanh chóng phát hiện và khắc phục sự cố trong quá trình vận hành.

3.3.6.6 Tối ưu chi phí vận hành Dựa trên dữ liệu giám sát, hệ thống có thể được tinh chỉnh để giảm các lần chạy pipeline không cần thiết, đồng thời tối ưu tài nguyên tính toán và truy vấn. Nhờ đó, chi phí vận hành được kiểm soát hiệu quả mà vẫn đảm bảo chất lượng và độ ổn định của hệ thống.




Hình 42: Thiết lập quy trình tự động hoá và tối ưu trong Microsoft Fabric

3.4 Kết quả phân tích & Thông tin chuyên sâu


3.4.1 Bảng báo cáo

Các bảng báo cáo và biểu đồ được xây dựng trực tiếp từ mô hình Semantic, phản ánh tổng quan dữ liệu cũng như các đặc điểm phân bố quan trọng của tập dữ liệu taxi NYC trong phạm vi phân tích.




Hình 43: Tổng quan dữ liệu thu được

Hình trên trình bày cái nhìn tổng thể về tập dữ liệu sau khi được xử lý và tối ưu ở tầng Gold, bao gồm quy mô số chuyến đi, các chỉ số vận hành chính và đặc điểm chung của hoạt động taxi trong khu vực đô thị New York.



Hình 44: Dữ liệu phân bố theo khu vực địa lý

Biểu đồ phân bố theo khu vực địa lý cho thấy sự tập trung lưu lượng chuyển đi tại các quận chính, qua đó làm nổi bật vai trò trung tâm của Manhattan so với các khu vực còn lại như Queens hay Brooklyn.



Hình 45: Phát hiện dữ liệu bất thường

Báo cáo phát hiện dữ liệu bất thường giúp nhận diện các chuyến đi có giá trị khác biệt so với phân bố chung, chẳng hạn như chuyến có thời gian hoặc chi phí bất thường, từ đó hỗ trợ công tác kiểm soát chất lượng dữ liệu và phân tích chuyên sâu.

3.4.2 Insight

Từ các báo cáo và biểu đồ trực quan, một số thông tin chuyên sâu quan trọng được rút ra như sau:

- **Quy mô và đặc tính chung:** Tập dữ liệu phân tích bao gồm khoảng 6 triệu chuyến đi. Tốc độ di chuyển trung bình vào khoảng 13 MPH, phản ánh đặc trưng giao thông có mật

độ cao của môi trường đô thị lớn như New York.

- **Sự tập trung theo khu vực địa lý:** Khoảng 4,8 triệu chuyến đi (tương đương gần 80% tổng lưu lượng) có liên quan đến khu vực Manhattan. Trong khi đó, số lượng chuyến đi tại Queens và Brooklyn thấp hơn đáng kể, cho thấy sự chênh lệch rõ rệt về nhu cầu di chuyển giữa các khu vực.
- **Đặc điểm hành khách:** Các chuyến đi với một hành khách chiếm tỷ lệ áp đảo, khoảng 78% tổng số chuyến. Điều này mở ra tiềm năng cho các chiến lược tối ưu như giới thiệu dịch vụ ghép chuyến (ride-pooling) hoặc các chương trình khuyến mãi nhằm tăng hiệu quả sử dụng phương tiện.
- **Các mốc thời gian quan trọng:** Nhu cầu di chuyển đạt mức cao nhất vào các ngày thứ Tư và thứ Năm. Khung giờ cao điểm buổi tối tập trung trong khoảng từ 18:00 đến 19:00, trong khi mức cầu thấp nhất ghi nhận vào rạng sáng từ 03:00 đến 05:00.
- **Khu vực sân bay:** Các chuyến đi liên quan đến sân bay Newark (EWR) có mức phí trung bình cao (khoảng trên 90 USD) và thời gian di chuyển dài (xấp xỉ 40 phút), phản ánh đặc thù quãng đường dài và chi phí vận hành cao của nhóm chuyến đi này.

3.4.3 Dữ liệu bất thường

Trong quá trình phân tích, kết quả cho thấy sự tồn tại của một số điểm dữ liệu bất thường (*anomalies*) có khả năng ảnh hưởng đến độ tin cậy và tính đại diện của các chỉ số tổng hợp. Dựa trên bản chất phát sinh và ý nghĩa nghiệp vụ, các điểm bất thường này được phân loại thành hai nhóm chính.

3.4.3.1 Nhóm Invalid Anomalies Nhóm bất thường không hợp lệ (Invalid Anomalies) chiếm dưới 1% tổng số bản ghi trong tập dữ liệu. Các bản ghi thuộc nhóm này có đặc điểm là khoảng cách chuyến đi vượt xa phạm vi địa lý hợp lý của khu vực nghiên cứu. Cụ thể, biểu đồ phân tán cho thấy một số chuyến đi có khoảng cách trung bình dao động từ khoảng 1.500 đến hơn 3.500 miles, trong khi tổng chi phí trung bình chỉ ở mức dưới 100 USD.

Những giá trị này không phù hợp với bối cảnh vận hành thực tế của dịch vụ taxi đô thị và nhiều khả năng bắt nguồn từ các vấn đề về chất lượng dữ liệu, chẳng hạn như lỗi cảm biến GPS, sai lệch đơn vị đo lường hoặc lỗi trong quá trình ánh xạ vị trí đón và trả khách. Mặc dù tỷ lệ xuất hiện của nhóm dữ liệu này là rất nhỏ và không gây ảnh hưởng đáng kể đến các kết quả

phân tích tổng thể, việc loại bỏ các bản ghi bất hợp lệ vẫn được khuyến nghị nhằm đảm bảo độ chính xác và tính nhất quán của tập dữ liệu.

3.4.3.2 Nhóm Business-valid Anomalies Nhóm bất thường hợp lệ về mặt nghiệp vụ (Business-valid Anomalies) chủ yếu liên quan đến các chuyến đi xuất phát hoặc kết thúc tại khu vực sân bay, đặc biệt là Newark Liberty International Airport (EWR). Kết quả phân tích theo khu vực cho thấy các chuyến đi này có khoảng cách trung bình tương đối ngắn (xấp xỉ 1–2 miles) nhưng lại có mức chi phí trung bình cao nhất trong toàn bộ tập dữ liệu, dao động trong khoảng 90–95 USD. Đồng thời, thời gian chuyến đi trung bình của nhóm này vào khoảng 40 phút.

Hiện tượng chi phí cao so với khoảng cách di chuyển phản ánh các yếu tố nghiệp vụ đặc thù của dịch vụ taxi sân bay, bao gồm cơ chế giá trọn gói (*flat-rate*), phụ phí sân bay và các khoản phí cầu đường. Do mang ý nghĩa kinh doanh hợp lệ, các bản ghi thuộc nhóm bất thường này không bị loại bỏ khỏi tập dữ liệu. Thay vào đó, việc tách riêng nhóm chuyến đi sân bay để phân tích độc lập được khuyến nghị, nhằm tránh làm sai lệch các chỉ số tổng hợp và đảm bảo tính chính xác trong đánh giá hiệu quả vận hành của toàn hệ thống.

3.4.4 Khuyến nghị vận hành & kinh doanh

Dựa trên các kết quả phân tích dữ liệu và insight thu được từ hệ thống báo cáo, một số khuyến nghị vận hành và chiến lược kinh doanh được đề xuất nhằm tối ưu hiệu quả khai thác đội xe, cải thiện trải nghiệm khách hàng và nâng cao hiệu suất tổng thể của hệ thống taxi đô thị.

3.4.4.a Tái phân bổ đội xe theo vùng – giờ

Phân tích lưu lượng cho thấy nhu cầu di chuyển tập trung cao tại khu vực Manhattan, đặc biệt trong khung giờ cao điểm buổi tối từ 17:00 đến 19:00, với cường độ mạnh hơn vào các ngày giữa tuần. Do đó, việc tăng cường phân bổ đội xe tại khu vực này trong khung thời gian nêu trên có thể giúp giảm thời gian chờ của khách hàng, đồng thời nâng cao số chuyến phục vụ trên mỗi phương tiện theo giờ.

Bên cạnh đó, hệ thống dashboard trực quan kết hợp heatmap và dữ liệu nguồn–đích (Origin/Destination) theo thời gian thực có thể được sử dụng để hỗ trợ điều phối động (*dynamic rebalancing*). Cách tiếp cận này cho phép luân chuyển đội xe linh hoạt giữa các khu vực dựa trên nhu cầu thực tế, thay vì phân bổ cố định theo kế hoạch tĩnh.

3.4.4.b Chiến lược giá cho khu vực sân bay

Các chuyến đi liên quan đến sân bay, đặc biệt là Newark Liberty International Airport (EWR), có đặc điểm chi phí cao và thời gian di chuyển dài, phản ánh các yếu tố nghiệp vụ như phụ phí sân bay và quãng đường đặc thù. Dựa trên đặc điểm này, việc triển khai mô hình giá trọn gói (*flat-rate*) hoặc giá cố định theo tuyến cho các chuyến sân bay được khuyến nghị.

Chiến lược giá này có thể mang lại nhiều lợi ích, bao gồm tăng khả năng cạnh tranh với các dịch vụ thay thế, giảm thời gian ra quyết định của khách hàng và cải thiện tỷ lệ lấp đầy đối với các chuyến đi dài. Đồng thời, mức giá rõ ràng và minh bạch cũng góp phần nâng cao trải nghiệm khách hàng trong các hành trình đặc thù như di chuyển ra sân bay.

3.4.4.c Khai thác cơ hội Ride-Pooling

Kết quả phân tích cho thấy các chuyến đi với một hành khách chiếm khoảng 78% tổng số chuyến, cho thấy tiềm năng lớn trong việc triển khai các mô hình ghép chuyến (*ride-pooling*). Đặc biệt, các hành lang giao thông có mật độ cao như khu vực Manhattan đến Midtown hoặc Downtown là những ứng viên phù hợp để thử nghiệm mô hình này trong các khung giờ thấp đến trung bình.

Một chiến lược khả thi là triển khai chương trình khuyến mãi cho hành khách chấp nhận ghép chuyến, chẳng hạn giảm giá từ 10% đến 20%. Thông qua các thử nghiệm A/B, hệ thống có thể đánh giá tác động của ride-pooling đến số lượng chuyến đi, thu nhập của tài xế và mức độ chấp nhận của khách hàng, từ đó đưa ra quyết định mở rộng hoặc điều chỉnh mô hình.

3.4.4.d Giảm chi phí vận hành và nâng cao công suất

Phân tích theo thời gian cho thấy nhu cầu di chuyển thấp nhất trong khung giờ rạng sáng từ 03:00 đến 05:00. Đây là khoảng thời gian phù hợp để sắp xếp các hoạt động bảo trì phương tiện, tiếp nhiên liệu hoặc nghỉ ca cho tài xế, qua đó giảm thiểu ảnh hưởng tiêu cực đến doanh thu trong giờ cao điểm.

Ngoài ra, việc khuyến khích mô hình làm việc linh hoạt, kết hợp tăng cường nhân sự và phương tiện trong các khung giờ cao điểm, có thể giúp nâng cao công suất khai thác tổng thể của đội xe. Các biện pháp này không chỉ góp phần giảm chi phí vận hành mà còn cải thiện hiệu quả sử dụng tài nguyên trong toàn hệ thống.

4 ĐÁNH GIÁ BẢN DÙNG THỬ

4.1 Ưu điểm của Microsoft Fabric Trial

Microsoft Fabric Trial mang lại nhiều lợi ích đáng kể cho mục tiêu học thuật và thử nghiệm công nghệ, đặc biệt trong giai đoạn xây dựng *proof-of-concept* (POC). Trước hết, gói dùng thử cho phép truy cập gần như đầy đủ hệ sinh thái Microsoft Fabric, bao gồm các thành phần cốt lõi như Data Engineering dựa trên Spark, SQL Analytics, Lakehouse, Power BI và một số tính năng Machine Learning cơ bản. Nhờ đó, người dùng có thể triển khai và đánh giá toàn bộ chu trình phân tích dữ liệu *end-to-end* trên một nền tảng thống nhất.

Bên cạnh đó, Microsoft Fabric được thiết kế như một nền tảng hợp nhất (*all-in-one platform*), tích hợp Data Factory, Spark, SQL và Power BI trong cùng một workspace. Cách tiếp cận này giúp đơn giản hóa kiến trúc hệ thống, giảm sự phụ thuộc vào nhiều dịch vụ rời rạc và rút ngắn đáng kể thời gian triển khai so với các mô hình phân tán truyền thống.

Với mô hình SaaS, Fabric Trial cho phép triển khai nhanh chóng mà không yêu cầu cấu hình hạ tầng hay quản lý tài nguyên vật lý. Người dùng có thể bắt đầu phân tích dữ liệu ngay sau khi kích hoạt tài khoản. Đặc biệt, trong thời gian dùng thử 60 ngày, toàn bộ quá trình đánh giá và kiểm thử hệ thống được thực hiện mà không phát sinh chi phí, phù hợp cho các mục tiêu nghiên cứu, học tập và thử nghiệm công nghệ.

Ngoài ra, OneLake được tích hợp sẵn như một kho dữ liệu tập trung, cho phép các workload như Spark, SQL và Power BI cùng truy cập một nguồn dữ liệu duy nhất. Điều này giúp giảm trùng lặp dữ liệu, đảm bảo tính nhất quán và tăng hiệu quả khai thác dữ liệu trong quá trình phân tích.

4.2 Hạn chế và thách thức

Mặc dù mang lại nhiều lợi ích, Microsoft Fabric Trial vẫn tồn tại một số hạn chế cần được xem xét. Trước hết, các khả năng Machine Learning nâng cao, đặc biệt là huấn luyện mô hình quy mô lớn, bị giới hạn trong môi trường trial, khiến việc triển khai các bài toán AI/ML phức tạp gặp nhiều khó khăn.

Về hiệu năng, do cơ chế giới hạn tài nguyên (*throttling*), các Spark và SQL jobs trong Fabric Trial có thể chạy chậm, thời gian khởi tạo cluster kéo dài và dễ phát sinh lỗi timeout đối với các pipeline có khối lượng xử lý lớn. Bên cạnh đó, dung lượng lưu trữ, số phiên Spark đồng thời và khả năng mở rộng tài nguyên đều bị giới hạn, ảnh hưởng đến các kịch bản phân tích dữ liệu quy



mô lớn.

Ngoài ra, việc tích hợp nhiều dịch vụ trong cùng một nền tảng khiến giao diện người dùng tương đối nặng và trong một số trường hợp phản hồi chưa thực sự mượt mà. Cuối cùng, gói trial không phù hợp cho môi trường sản xuất do không cung cấp SLA, tiềm ẩn nguy cơ bị reset dữ liệu và thiếu các tính năng quản trị, tự động hóa cần thiết cho vận hành hệ thống dài hạn.

Tóm lại, Microsoft Fabric Trial là một lựa chọn phù hợp cho mục đích học thuật và thử nghiệm ban đầu, nhưng cần cân nhắc kỹ lưỡng các hạn chế về tài nguyên, hiệu năng và khả năng mở rộng trước khi triển khai trong môi trường sản xuất thực tế.

5 TÀI LIỆU THAM KHẢO

1. Alphabold. *Microsoft Fabric vs Databricks: Which Is Best for Your Data Needs?* <https://www.alphabold.com>
2. Chaos Genius. *Microsoft Fabric vs Databricks.* <https://www.chaosgenius.io>
3. DataKulture. *Microsoft Fabric vs Databricks.* <https://datakulture.com>
4. Databricks. *Databricks Named a Leader in the 2025 Gartner Magic Quadrant for Cloud Database Management Systems.* <https://www.databricks.com>
5. Edyau. (2023). *Microsoft Purview with Databricks.* Medium. <https://medium.com>
6. Kanerika. *Databricks vs Snowflake vs Microsoft Fabric.* <https://kanerika.com>
7. Kanerika. *Microsoft Fabric vs Azure Synapse: Key Differences.* <https://kanerika.com>
8. Microsoft Corporation. *A Unified End-to-End SaaS Data Platform: All-in-One – Simplifying Everything.* Tài liệu PDF nội bộ.
9. Microsoft Learn. *Migrate from Azure Synapse Data Explorer to Eventhouse in Microsoft Fabric.* <https://learn.microsoft.com>
10. Neena, N. (2024). *Microsoft Fabric vs Databricks: A Practical Decision Framework.* Medium. <https://medium.com>